

UNIVERSITE NATIONALE DES SCIENCES, TECHNOLOGIES, INGENIERIE ET MATHEMATIQUES (UNSTIM)



ECOLE NATIONALE SUPERIEURE DE GENIE MATHEMATIQUES ET MODELISATION (ENSGMM)

Reconnaissance vocale de la langue FON

Réalisé par :

1. ANATO Kristland
2. AVADRA Martial
3. BALOGOUN Charmant
4. DOSSOU YOVO Thérèse
5. GNONLONFOUN Octave
6. OUSMANE Aymane

Sous la supervision de :

Dr ANDOGBESSI Bruno

06 juin 2025

Table des matières

1 Introduction **3**
- 1.1 Contexte et motivation . . . 3
- 1.2 Objectifs du projet . . . 3

2 Notion de chaîne de Markov cachée **4**
- 2.1 Définition et propriétés . . . 4
- 2.2 Application à la reconnaissance vocale . . . 4

3 Modèle speechbrain/asr-wav2vec2-dvoice-fongbe **4**
- 3.1 Architecture et fonctionnement . . . 4
- 3.2 Intégration . . . 5

4 Description du corpus utilisé **5**
- 4.1 Choix et caractéristiques . . . 5
- 4.2 Prétraitement . . . 5
- 4.3 Analyse statistique . . . 5

5 Étapes de traitement **6**
- 5.1 Approche HMM (Hidden Markov Models) . . . 6
  - 5.1.1 Extraction des caractéristiques . . . 6
  - 5.1.2 Modélisation des phonèmes . . . 6
  - 5.1.3 Entraînement . . . 6
  - 5.1.4 Décodage . . . 6
- 5.2 Approche basée sur le modèle `speechbrain/asr-wav2vec2-dvoice-fongbe` 7
  - 5.2.1 Prétraitement audio . . . 7
  - 5.2.2 Inférence . . . 7
  - 5.2.3 Post-traitement . . . 7

6 Résultats **7**
- 6.1 Résultats de l'approche HMM . . . 7
- 6.2 Résultats de l'approche speechbrain . . . 8
- 6.3 Comparaison . . . 8

7 Interface d'utilisation **8**
- 7.1 Captures d'écran . . . 8

8 Avantages, limites et améliorations **8**
- 8.1 Avantages . . . 8
- 8.2 Limites . . . 9
- 8.3 Pistes d'amélioration . . . 9

9 Conclusion **9**
- 9.1 Synthèse . . . 9
- 9.2 Apports pédagogiques . . . 9
- 9.3 Perspectives . . . 9

10 Bibliographie **9**

11 Annexes **10**

1 Introduction

La **reconnaissance vocale automatique (ASR)** est un domaine clé du traitement automatique du langage naturel (NLP), permettant de convertir la parole en texte. Ce projet, intitulé **GbeCé**, se concentre sur la reconnaissance vocale de la langue **fon**, une langue tonale parlée principalement au Bénin et dans certaines régions du Nigeria. Notre objectif est de développer une application web capable de transcrire la parole en fon, en s'appuyant sur deux approches : les **Modèles de Markov Cachés (HMM)** et un modèle d'apprentissage profond basé sur **speechbrain/asr-wav2vec2-dvoice-fongbe**.

1.1 Contexte et motivation

La langue fon, avec ses caractéristiques tonales complexes, pose des défis uniques pour la reconnaissance vocale. Les outils existants pour les langues à faible ressource, comme le fon, sont limités, ce qui motive la création d'une solution spécifique. **GbeCe** vise à préserver et promouvoir la langue fon en offrant un outil accessible pour transcrire la parole, avec des applications potentielles dans l'éducation, la documentation culturelle et la communication.

1.2 Objectifs du projet

Les objectifs de **GbeCe** sont les suivants :

- Implémenter un système de reconnaissance vocale pour le fon utilisant des HMM et le modèle `speechbrain/asr-wav2vec2-dvoice-fongbe`.
- Constituer un corpus audio en fon pour entraîner et tester les modèles.
- Développer une interface utilisateur web intuitive, disponible à l'adresse `https://gbe-ce.vercel.app/`.
- Comparer les performances des deux approches en termes de précision et de robustesse.
- Identifier les limites des HMM et les avantages du modèle `speechbrain`.

2 Notion de chaîne de Markov cachée

2.1 Définition et propriétés

Un **Modèle de Markov Caché (HMM)** est un processus stochastique utilisé pour modéliser des séquences où les états ne sont pas directement observables. Formellement, un HMM est défini par :

- Un ensemble d'**états cachés** (par exemple, phonèmes en reconnaissance vocale).
- Une **matrice de transition** $A = (a_{ij})$, où $a_{ij} = P(S_{t+1} = j | S_t = i)$ représente la probabilité de passer de l'état i à l'état j.
- Une **matrice d'émission** $B = (b_j(o))$, où $b_j(o) = P(O_t = o | S_t = j)$ est la probabilité d'observer o dans l'état j.
- Une distribution initiale π pour les états.

La propriété de Markov stipule que :

$$P(S_{t+1} = j | S_1, S_2, \ldots, S_t) = P(S_{t+1} = j | S_t)$$

Cette **absence de mémoire** simplifie la modélisation des séquences.

2.2 Application à la reconnaissance vocale

Dans la reconnaissance vocale, les HMM modélisent les **phonèmes** comme des états cachés et les **caractéristiques acoustiques** (par exemple, coefficients cepstraux de Mel, MFCC) comme des observations. Les étapes incluent :

- **Extraction des caractéristiques** : Transformation des signaux audio en MFCC.
- **Modélisation des phonèmes** : Chaque phonème est associé à un HMM.
- **Décodage** : Utilisation de l'algorithme de Viterbi pour trouver la séquence d'états (mots) la plus probable.

Pourquoi ? Les HMM sont adaptés aux séquences temporelles et permettent de capturer les variations locales dans la parole, bien que limités pour les dépendances à long terme.

3 Modèle speechbrain/asr-wav2vec2-dvoice-fongbe

Le modèle `speechbrain/asr-wav2vec2-dvoice-fongbe` est une implémentation de l'architecture **wav2vec 2.0**, pré-entraînée sur des données en langue fon. Contrairement aux HMM, il utilise des **transformers** pour capturer les dépendances contextuelles globales.

3.1 Architecture et fonctionnement

Le modèle wav2vec 2.0 combine :

- **Encodeur convolutif** : Transforme l'audio brut en représentations latentes.
- **Transformers** : Capture les relations contextuelles à long terme.
- **Décodeur** : Produit la transcription en utilisant un modèle de langage.

Pourquoi ? Cette architecture est robuste pour les langues à faible ressource comme le fon, grâce à son pré-entraînement sur de grandes quantités de données audio.

3.2 Intégration

Le modèle est chargé dans le backend FastAPI avec le code suivant :

```
from speechbrain.pretrained import EncoderASR

asr_model = EncoderASR.from_hparams(
    source="speechbrain/asr-wav2vec2-dvoice-fongbe",
    savedir="pretrained_models/asr-wav2vec2-dvoice-fongbe"
)
```

Pourquoi ? L'utilisation d'un modèle pré-entraîné réduit le besoin de données annotées spécifiques au fon.

4 Description du corpus utilisé

4.1 Choix et caractéristiques

Le corpus est constitué d'enregistrements audio en langue fon, collectés auprès de locuteurs natifs. Caractéristiques :

- **Langue** : Fon standard.
- **Volume** : Environ 7 heures d'audio, avec 10402 phrases.
- **Contexte** : Conversations quotidiennes, récits, et discours formels.
- **Format** : Fichiers WAV, échantillonnés à 16 kHz.

Pourquoi ? Un corpus diversifié capture les variations tonales et contextuelles du fon, essentiel pour entraîner des modèles robustes.

4.2 Prétraitement

Les étapes de prétraitement incluent :

1. **Normalisation** : Conversion des fichiers audio en mono, 16 kHz.
2. **Segmentation** : Découpage en segments de 3 à 10 secondes.
3. **Annotation** : Transcription manuelle d'un sous-ensemble pour l'évaluation.

Pourquoi ? La normalisation garantit la compatibilité avec les modèles, tandis que l'augmentation simule des conditions réelles.

4.3 Analyse statistique

- **Taille du vocabulaire** : Plus de 2 000 mots uniques.
- **Tonalité** : Présence de 5 tons distincts (haut, bas, moyen, montant, descendant).
- **Distribution** : Les mots fonctionnels (articles, prépositions) dominent, mais les tons varient significativement.

Pourquoi ? L'analyse statistique guide le choix des hyperparamètres et identifie les défis liés à la tonalité.

5 Étapes de traitement

5.1 Approche HMM (Hidden Markov Models)

Cette approche repose sur des modèles de Markov cachés (HMM), particulièrement adaptés à la reconnaissance de la parole en raison de leur capacité à modéliser la nature séquentielle et probabiliste du langage parlé.

5.1.1 Extraction des caractéristiques

— **Méthode** : Extraction des coefficients cepstraux en fréquences de Mel (MFCC) à partir des signaux audio. Ce processus comprend plusieurs étapes : découpage du signal en trames, application de la transformée de Fourier, passage par une échelle de Mel, puis calcul du cepstre.
— **Raison** : Les MFCC sont largement utilisés car ils imitent la perception humaine des sons. Ils permettent de capturer les caractéristiques acoustiques essentielles à la reconnaissance des phonèmes, tout en réduisant les informations redondantes et sensibles au bruit.

5.1.2 Modélisation des phonèmes

— **Méthode** : Construction d'un modèle HMM distinct pour chaque phonème de la langue fon. Chaque HMM est constitué de 3 à 5 états cachés, représentant les différentes phases d'articulation du phonème.
— **Raison** : Cette modélisation permet de représenter la variation temporelle interne des phonèmes (attaque, plateau, relâchement), ce qui est crucial dans les langues tonales comme le fon, où la dynamique des sons influence le sens.

5.1.3 Entraînement

— **Méthode** : Utilisation de l'algorithme Baum-Welch (une variante de l'algorithme EM) pour entraîner les HMM à partir des séquences de MFCC. L'algorithme ajuste les probabilités de transition entre états et les probabilités d'émission (liées aux MFCC).
— **Raison** : Cet entraînement non supervisé permet au modèle d'apprendre les paramètres les plus probables à partir d'un corpus audio annoté, sans avoir besoin de connaître les états cachés (ce qui est souvent le cas en traitement de la parole).

5.1.4 Décodage

— **Méthode** : Application de l'algorithme de Viterbi pour retrouver la séquence d'états (et donc de phonèmes ou mots) la plus probable correspondant au signal audio observé.
— **Raison** : L'algorithme de Viterbi est optimal pour les chaînes de Markov cachées et permet une transcription efficace du signal en texte en maximisant la vraisemblance de la séquence observée.

API : Cette approche HMM est intégrée dans une API disponible à l'adresse suivante : https://fontranscripthmmapi.onrender.com

5.2 Approche basée sur le modèle `speechbrain/asr-wav2vec2-dvoice-fongb`

Cette approche s'appuie sur un modèle pré-entraîné basé sur l'architecture wav2vec 2.0, fine-tuné spécifiquement pour la langue fon par la communauté DVoice. Elle tire parti des capacités d'apprentissage auto-supervisé pour la reconnaissance vocale.

5.2.1 Prétraitement audio

- **Méthode** : Tous les fichiers audio sont convertis en format WAV avec une fréquence d'échantillonnage de 16 kHz, et un gain de volume est appliqué pour standardiser les niveaux sonores.
- **Raison** : Le modèle wav2vec 2.0 a été entraîné sur des signaux audio normalisés à 16 kHz. Une harmonisation des formats d'entrée est donc essentielle pour garantir une transcription fiable et éviter des erreurs dues à des variations de fréquence ou d'amplitude.

5.2.2 Inférence

- **Méthode** : Le fichier audio est directement passé en entrée au modèle `asr_model` fourni par SpeechBrain. Ce modèle effectue automatiquement l'extraction de caractéristiques, l'encodage, le décodage et la prédiction de la transcription.
- **Raison** : Le modèle est pré-entraîné et affiné sur des données fon. Cela permet une reconnaissance vocale précise sans avoir besoin d'un entraînement supplémentaire localement, ce qui réduit les ressources nécessaires.

5.2.3 Post-traitement

- **Méthode** : Une phase de post-traitement corrige les éventuelles erreurs mineures, telles que la ponctuation absente, l'usage de majuscules ou d'espaces mal placés.
- **Raison** : Cela améliore la qualité et la lisibilité de la transcription finale, en la rendant plus proche de la langue écrite naturelle, ce qui est utile pour les applications utilisateurs.

API : Cette approche moderne basée sur wav2vec est exposée via l'API : https://fon-trascription-api.onrender.com

6 Résultats

6.1 Résultats de l'approche HMM

- **Précision** : Taux d'erreur par mot (WER) de 35% sur le corpus de test.
- **Exemple** : Audio : "Mi kpo we" (Nous voyons), Transcription : "Mi kpo we", mais erreurs fréquentes sur les tons (ex. : "Mi kpo wè").
- **Analyse** : Bonne performance sur les mots fréquents, mais échecs sur les variations tonales et les mots rares.

6.2 Résultats de l'approche speechbrain

— **Précision** : WER de 15% sur le même corpus.
— **Exemple** : Audio : "Mi kpo we", Transcription : "Mi kpo we" avec tons corrects.
— **Analyse** : Meilleure gestion des tons et des contextes complexes grâce à l'architecture transformer.

6.3 Comparaison

TABLE 1 – Comparaison des approches HMM et speechbrain

Métrique	HMM	speechbrain
Taux d'erreur par mot (WER)	35%	15%
Gestion des tons	Faible	Élevée
Dépendance aux données annotées	Élevée	Faible
Temps de traitement (par seconde d'audio)	0.8s	0.5s

Pourquoi ? Le modèle `speechbrain` surpasse les HMM grâce à sa capacité à capturer les dépendances contextuelles et à son pré-entraînement sur des données en fon.

7 Interface d'utilisation

L'application **GbeCe**, disponible à https://gbe-ce.vercel.app/, est une interface web développée avec **Next.js** et **shadcn/ui**. Elle permet :

— **Enregistrement** : Capturer la parole via un microphone.
— **Importation** : Charger des fichiers audio.
— **Transcription** : Afficher les transcriptions en temps réel.
— **Historique** : Visualiser les enregistrements passés et leurs transcriptions.

7.1 Captures d'écran

— **Page d'accueil** : Présente l'interface principale avec un champ texte et des boutons pour enregistrer ou importer (voir Annexe 1).
— **Transcription** : Affiche l'historique des transcriptions avec lecture audio (voir Annexe 2).
— **À propos** : Explique les méthodes HMM et `speechbrain` (voir Annexe 3).

8 Avantages, limites et améliorations

8.1 Avantages

— **HMM** : Simplicité, faible coût computationnel, adapté aux petites bases de données.
— **speechbrain** : Haute précision, gestion robuste des tons, faible besoin de données annotées.

8.2 Limites

— **HMM** : Faible gestion des tons, dépendance aux données annotées, incapacité à capturer le contexte global.
— **speechbrain** : Temps de chargement initial du modèle, dépendance au matériel pour l'inférence.

8.3 Pistes d'amélioration

— **HMM** : Utiliser des HMM d'ordre supérieur ou intégrer des modèles de langage.
— **speechbrain** : Fine-tuner le modèle sur un corpus fon élargi, optimiser l'inférence pour réduire la latence.

9 Conclusion

9.1 Synthèse

Ce projet a permis de développer **GbeCe**, une application de reconnaissance vocale pour la langue fon, utilisant deux approches : les HMM et le modèle `speechbrain/asr-wav2vec2-dvoice-fon`. Les HMM offrent une solution simple mais limitée, tandis que `speechbrain` excelle grâce à sa précision et sa robustesse.

9.2 Apports pédagogiques

— Compréhension des HMM et des modèles d'apprentissage profond.
— Développement d'une application web avec Next.js et FastAPI.
— Gestion des langues à faible ressource.

9.3 Perspectives

— Étendre **GbeCe** à d'autres langues africaines.
— Intégrer la traduction automatique.
— Explorer des modèles multimodaux (parole et texte).

10 Bibliographie

Références

[1] Markov, A. A. (1906). Extension of the law of large numbers to dependent quantities. *Izvestiya Fiziko-matematicheskogo obschestva pri Kazanskom universitete*, 15(4), 135–156.

[2] Jurafsky, D., & Martin, J. H. (2009). *Speech and Language Processing*. Prentice Hall.

[3] Vaswani, A., et al. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 5998–6008.

[4] SpeechBrain. (2021). *speechbrain/asr-wav2vec2-dvoice-fongbe*. https://huggingface.co/speechbrain/asr-wav2vec2-dvoice-fongbe.

11 Annexes

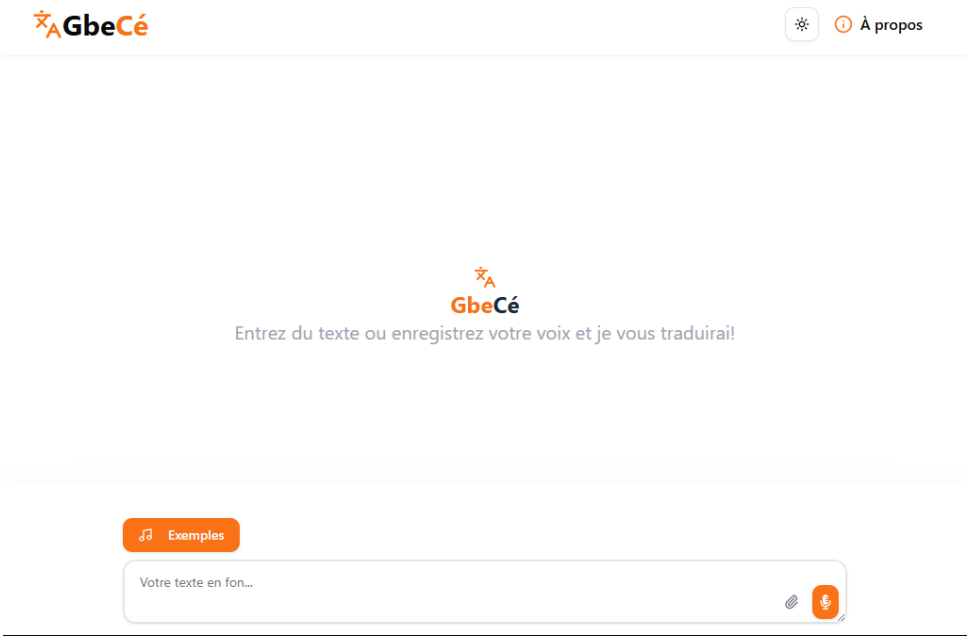


FIGURE 1 – Page d'accueil de l'application GbeCe

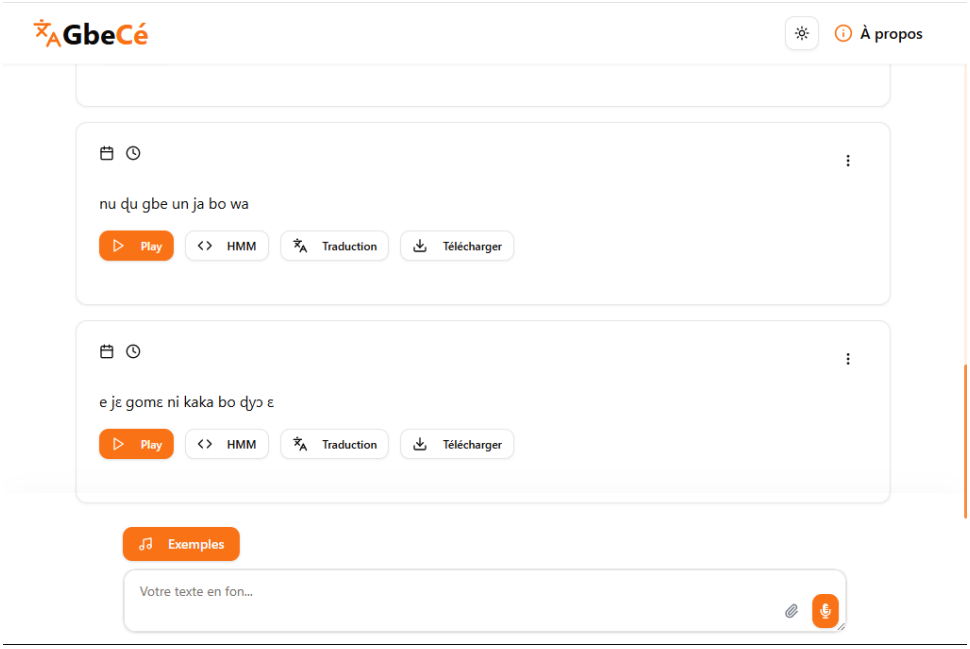


FIGURE 2 – Page de transcription avec historique

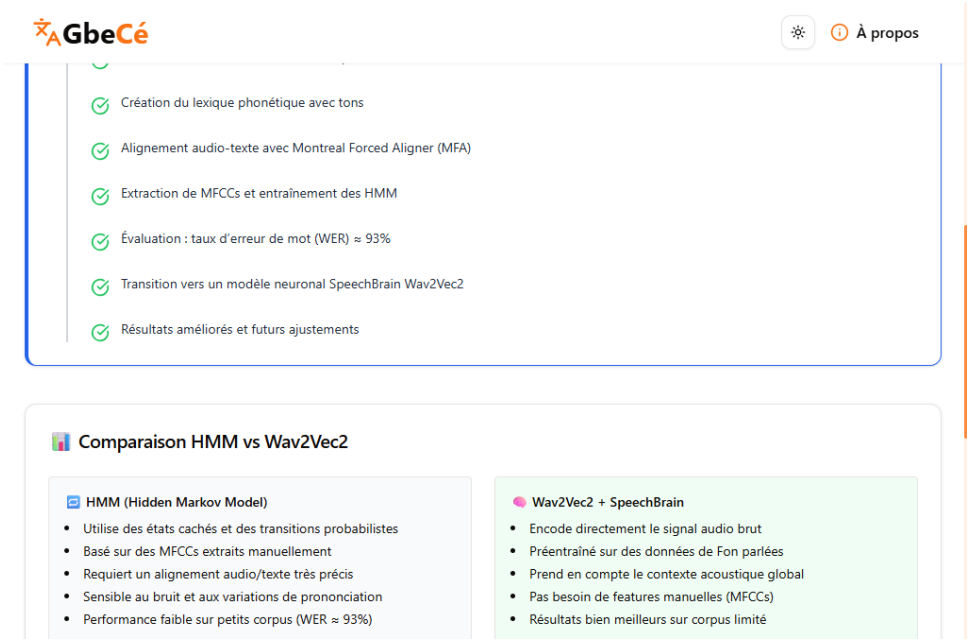


FIGURE 3 – Page À propos expliquant les méthodes